INVESTIGACIÓN · CONSULTA · APRENDIZAJE

Glosario académico de Inteligencia Artificial

60 términos esenciales en 12 ejes temáticos
+ 12 conceptos de IA contemporánea

ASIGNATURA	Inteligencia Artificial I
EQUIPO	Karen Yulieth Gómez Núñez Juan José Ochoa Romero Jesica Lorena Osorio Fernández
FECHA	4 de noviembre de 2026
TIPO DE DOCUMENTO	Glosario de consulta

Cómo usarlo: navega por eje o índice alfabético, identifica cada término por su número y sigue las referencias [n] hasta el localizador indicado. Todos los ejemplos son hipotéticos salvo cuando se señalan como cálculos.

Presentación y alcance

Este glosario organiza sesenta términos de Inteligencia Artificial I en fichas uniformes. Cada ficha distingue definición técnica parafraseada, explicación didáctica, aplicación hipotética o ejemplo calculado, conexiones con otras entradas y fuentes identificables.

La selección responde a la guía «IA en juego»: 48 entradas distribuidas por igual entre doce ejes y doce adicionales sobre IA contemporánea. Los conceptos se redactaron de forma original y se contrastaron principalmente con documentación de proveedores técnicos, documentación abierta, portales institucionales y los mapas temáticos de las dos obras base.

Nota metodológica importante

Esta es una edición de trabajo académica. Se consultaron materiales web y se identificaron los dos libros exigidos, pero el equipo debe leer los pasajes concretos de los ejemplares de Theobald y Burkov antes de declarar terminada su verificación bibliográfica. Las definiciones no se presentan como citas literales. También es necesario que el equipo compruebe manualmente todos los enlaces, nombres de integrantes y fecha final de entrega. El uso de asistencia de IA para proponer y editar texto debe declararse.

Ejemplos de distinciones importantes

IA ≠ ML — La IA engloba enfoques; el aprendizaje automático es uno de ellos.

Clasificación ≠ regresión — Clasificación predice categorías; regresión estima valores.

Probabilidad ≠ odds — 0,75 es una probabilidad; 3:1 son las odds correspondientes.

RAG ≠ ajuste fino — RAG recupera contexto externo; ajuste fino modifica parámetros mediante entrenamiento.

Agente RL ≠ agente generativo — Comparten la idea de tomar acciones, pero usan marcos y objetivos diferentes.

Cobertura: 60 / 60 conceptos · 13 secciones · 23 referencias · todos con ejemplos y referencias cruzadas.

Índice por ejes

Haz clic en cualquier concepto para ir directamente a su ficha numerada.

01. Generalidades de ML

01 Inteligencia artificial (IA) · 02 Aprendizaje automático (ML) · 03 Conjunto de datos · 04 Inferencia

02. Aprendizaje supervisado

05 Aprendizaje supervisado · 06 Etiqueta · 07 Clasificación · 08 Regresión

03. Aprendizaje no supervisado

09 Agrupamiento · 10 K-means · 11 DBSCAN · 12 Análisis de componentes principales (PCA)

04. Aprendizaje profundo

13 Aprendizaje profundo · 14 Aprendizaje de representaciones · 15 Convolución · 16 Descenso de gradiente

05. Aprendizaje por refuerzo

17 Agente de aprendizaje por refuerzo · 18 Entorno · 19 Política · 20 Recompensa

06. Algoritmos y aplicaciones

21 Regresión logística · 22 Árbol de decisión · 23 Bosque aleatorio · 24 Máquina de vectores de soporte (SVM)

07. Odds y probabilidades

25 Probabilidad · 26 Odds (razón a favor) · 27 Log-odds (logit) · 28 Razón de momios (odds ratio)

08. Texto computacional

29 Procesamiento del lenguaje natural (PLN) · 30 Tokenización · 31 TF-IDF · 32 Embedding

09. Vecino más cercano

33 K vecinos más cercanos (KNN) · 34 Número de vecinos K · 35 Distancia euclidiana · 36 Escalado de características

10. Principios de redes neuronales

37 Neurona artificial · 38 Pesos de una red · 39 Sesgo neuronal · 40 Retropropagación

11. Estructura de redes neuronales

41 Capas neuronales · 42 Red neuronal convolucional (CNN) · 43 Red neuronal recurrente (RNN) · 44 Transformer

12. Implicaciones sociales

45 Sesgo algorítmico · 46 Explicabilidad · 47 Privacidad de datos · 48 Supervisión humana

13. Ampliación: IA contemporánea

49 Inteligencia artificial generativa · 50 Modelo de lenguaje grande (LLM) · 51 Modelo fundacional · 52 Generación aumentada por recuperación (RAG) · 53 Agente de IA · 54 Inteligencia artificial multimodal · 55 Prompt (instrucción de entrada) · 56 Ajuste fino · 57 Alucinación de IA · 58 Base de datos vectorial · 59 Modelo de difusión · 60 Gobernanza de IA

Índice alfabético

Haz clic en un término para abrir su ficha. El orden ignora tildes y mayúsculas.

A

17 Agente de aprendizaje por refuerzo
53 Agente de IA
09 Agrupamiento
56 Ajuste fino
57 Alucinación de IA
12 Análisis de componentes principales (PCA)
02 Aprendizaje automático (ML)
14 Aprendizaje de representaciones
13 Aprendizaje profundo
05 Aprendizaje supervisado
22 Árbol de decisión

B

58 Base de datos vectorial
23 Bosque aleatorio

C

41 Capas neuronales
07 Clasificación
03 Conjunto de datos
15 Convolución

D

11 DBSCAN
16 Descenso de gradiente
35 Distancia euclidiana

E

32 Embedding
18 Entorno
36 Escalado de características
06 Etiqueta
46 Explicabilidad

G

52 Generación aumentada por recuperación (RAG)
60 Gobernanza de IA

I

04 Inferencia
01 Inteligencia artificial (IA)
49 Inteligencia artificial generativa
54 Inteligencia artificial multimodal

K

33 K vecinos más cercanos (KNN)
10 K-means

L

27 Log-odds (logit)

M

24 Máquina de vectores de soporte (SVM)
59 Modelo de difusión
50 Modelo de lenguaje grande (LLM)
51 Modelo fundacional

N

37 Neurona artificial
34 Número de vecinos K

O

26 Odds (razón a favor)

P

38 Pesos de una red
19 Política
47 Privacidad de datos
25 Probabilidad
29 Procesamiento del lenguaje natural (PLN)
55 Prompt (instrucción de entrada)

R

28 Razón de momios (odds ratio)
20 Recompensa
42 Red neuronal convolucional (CNN)
43 Red neuronal recurrente (RNN)
08 Regresión
21 Regresión logística
40 Retropropagación

S

45 Sesgo algorítmico
39 Sesgo neuronal
48 Supervisión humana

T

31 TF-IDF
30 Tokenización
44 Transformer

01 · Generalidades de ML

Fichas numeradas, fuentes rastreables y conexiones con otras entradas.

01 · Inteligencia artificial (IA)

Artificial intelligence (AI)

Definición técnica: Sistemas basados en máquinas que, para objetivos explícitos o implícitos, infieren a partir de entradas cómo generar predicciones, contenidos, recomendaciones o decisiones con distintos grados de autonomía [15].

En palabras sencillas: La IA es el campo general: no todo sistema de IA necesita entrenar un modelo de aprendizaje automático.

Aplicación: Hipotético: un asistente virtual clasifica solicitudes y propone respuestas antes de que una persona las revise.

Conexiones: Aprendizaje automático (02); inferencia (04); agentes de IA (53).

Fuente específica: [15] · apartado «Updated OECD Definition of an AI System».

---

02 · Aprendizaje automático (ML)

Machine learning (ML)

Definición técnica: Subcampo de IA que construye modelos cuyos parámetros o reglas se ajustan a partir de datos para mejorar la ejecución de tareas sin especificar manualmente cada decisión [1], [2], [3].

En palabras sencillas: En lugar de programar todas las respuestas, enseñamos al sistema con ejemplos o señales de experiencia.

Aplicación: Hipotético: aprender una función que estime la demanda diaria a partir de registros históricos.

Conexiones: Inteligencia artificial (01); aprendizaje supervisado (05); aprendizaje profundo (13).

Fuente específica: [1], [2], [3] · [1], cap. «What is Machine Learning?»; [2], cap. 1.1 «What is Machine Learning»; [3], voz «machine learning».

---

03 · Conjunto de datos

Dataset

Definición técnica: Colección organizada de observaciones o ejemplos, habitualmente descritos mediante características y, cuando existen, variables objetivo [3].

En palabras sencillas: Es el material del que el algoritmo extrae regularidades; su calidad condiciona el resultado.

Aplicación: Hipotético: tabla con fecha, temperatura, producto y unidades vendidas.

Conexiones: Aprendizaje automático (02); etiqueta (06); agrupamiento (09).

Fuente específica: [3] · voz «dataset».

---

04 · Inferencia

Inference

Definición técnica: Etapa en la que un modelo ya entrenado procesa nuevas entradas y produce una predicción, clasificación, representación o respuesta [3].

En palabras sencillas: Entrenar es aprender patrones; inferir es aplicar lo aprendido a un caso que llega después.

Aplicación: Hipotético: el modelo recibe los datos de una nueva transacción y estima su riesgo.

Conexiones: Conjunto de datos (03); clasificación (07); modelo de lenguaje grande (50).

Fuente específica: [3] · voz «inference».

---

02 · Aprendizaje supervisado

Fichas numeradas, fuentes rastreables y conexiones con otras entradas.

05 · Aprendizaje supervisado

Supervised learning

Definición técnica: Paradigma de ML en el que un algoritmo ajusta una función con ejemplos que asocian entradas a etiquetas o valores objetivo conocidos [2], [3].

En palabras sencillas: En el entrenamiento se conoce la respuesta esperada de los ejemplos, aunque no la de casos nuevos.

Aplicación: Hipotético: historiales de crédito con etiqueta de pago o incumplimiento.

Conexiones: Etiqueta (06); clasificación (07); regresión (08).

Fuente específica: [2], [3] · [2], cap. 1.2.1 «Supervised Learning»; [3], voz «supervised learning».

---

06 · Etiqueta

Label / target

Definición técnica: Valor de salida observado que se utiliza como referencia durante el entrenamiento y la evaluación de modelos supervisados [3].

En palabras sencillas: Es la respuesta que queremos aprender a predecir; puede ser una categoría o un número.

Aplicación: Hipotético: «fraude / no fraude» para transacciones previamente investigadas.

Conexiones: Aprendizaje supervisado (05); clasificación (07); regresión (08).

Fuente específica: [3] · voces «label» y «target».

---

07 · Clasificación

Classification

Definición técnica: Tarea predictiva en la que la variable objetivo pertenece a un conjunto discreto de clases [2], [3].

En palabras sencillas: El resultado es una categoría, no una cantidad continua.

Aplicación: Hipotético: asignar un correo a «spam» o «legítimo».

Conexiones: Etiqueta (06); regresión (08); regresión logística (21).

Fuente específica: [2], [3] · [2], cap. 2.7 «Classification vs. Regression»; [3], voz «classification».

---

08 · Regresión

Regression

Definición técnica: Tarea supervisada destinada a predecir una variable objetivo numérica, usualmente continua, a partir de características de entrada [2], [6].

En palabras sencillas: Se busca estimar cuánto vale algo, no escoger entre categorías.

Aplicación: Hipotético: predecir el consumo de energía en kWh para el día siguiente.

Conexiones: Clasificación (07); regresión logística (21); bosque aleatorio (23).

Fuente específica: [2], [6] · [2], cap. 2.7; [6], apartado «Ordinary Least Squares».

---

03 · Aprendizaje no supervisado

Fichas numeradas, fuentes rastreables y conexiones con otras entradas.

09 · Agrupamiento

Clustering

Definición técnica: Familia de métodos no supervisados que identifica grupos de observaciones según una medida de similitud o estructura en los datos [4].

En palabras sencillas: Busca conjuntos parecidos sin disponer de la etiqueta de grupo correcta de antemano.

Aplicación: Hipotético: segmentar máquinas por vibraciones, temperatura y consumo eléctrico.

Conexiones: K-means (10); DBSCAN (11); análisis de componentes principales (12).

Fuente específica: [4] · sec. «2.3 Clustering» y «Overview of clustering methods».

---

10 · K-means

K-means clustering

Definición técnica: Algoritmo de agrupamiento que divide las muestras en K grupos y minimiza la suma de distancias cuadráticas de cada muestra a su centroide [4].

En palabras sencillas: Asignamos cada registro al centro más próximo y recalculamos centros hasta estabilizarlos.

Aplicación: Hipotético: agrupar clientes en cuatro perfiles según gasto y frecuencia de compra.

Conexiones: Agrupamiento (09); DBSCAN (11); distancia euclidiana (35).

Fuente específica: [4] · sec. «2.3.2 K-means».

---

11 · DBSCAN

Density-Based Spatial Clustering of Applications with Noise

Definición técnica: Método de agrupamiento basado en densidad que identifica regiones densas conectadas y puede marcar observaciones como ruido [4].

En palabras sencillas: A diferencia de K-means, no necesita fijar el número de grupos de antemano y admite formas irregulares.

Aplicación: Hipotético: detectar concentraciones de ubicaciones GPS y puntos aislados.

Conexiones: Agrupamiento (09); K-means (10); distancia euclidiana (35).

Fuente específica: [4] · sec. «2.3.7 DBSCAN».

---

12 · Análisis de componentes principales (PCA)

Principal component analysis (PCA)

Definición técnica: Técnica de reducción de dimensionalidad que proyecta variables numéricas centradas sobre direcciones ortogonales de máxima varianza [18].

En palabras sencillas: Resume varias columnas correlacionadas en componentes que conservan buena parte de la variabilidad.

Aplicación: Hipotético: sintetizar 20 medidas de sensores en tres componentes para visualizar patrones.

Conexiones: Conjunto de datos (03); agrupamiento (09); escalado (36).

Fuente específica: [18] · sec. «2.5.1 Principal component analysis».

---

04 · Aprendizaje profundo

Fichas numeradas, fuentes rastreables y conexiones con otras entradas.

13 · Aprendizaje profundo

Deep learning

Definición técnica: Subfamilia de ML que utiliza modelos compuestos por múltiples capas de transformación para aprender representaciones de distintos niveles de abstracción [17].

En palabras sencillas: Las capas sucesivas construyen características útiles a partir de las anteriores.

Aplicación: Hipotético: una red aprende bordes, texturas y luego defectos visibles en una pieza.

Conexiones: Aprendizaje automático (02); convolución (15); capas neuronales (41).

Fuente específica: [17] · voz «deep learning».

---

14 · Aprendizaje de representaciones

Representation learning

Definición técnica: Enfoque que aprende automáticamente transformaciones útiles de los datos, en vez de depender exclusivamente de características diseñadas manualmente [17].

En palabras sencillas: El modelo descubre cómo codificar la información para resolver mejor una tarea.

Aplicación: Hipotético: extraer patrones de audio de maquinaria sin definir manualmente cada descriptor.

Conexiones: Aprendizaje profundo (13); embedding (32); capas neuronales (41).

Fuente específica: [17] · voces «representation» y «embedding».

---

15 · Convolución

Convolution

Definición técnica: Operación que aplica filtros locales sobre una señal o matriz para obtener mapas de características mediante productos y sumas compartiendo parámetros [17].

En palabras sencillas: Un mismo detector de bordes puede recorrer diferentes regiones de una imagen.

Aplicación: Hipotético: localizar grietas superficiales en fotografías de soldaduras.

Conexiones: Aprendizaje profundo (13); redes convolucionales CNN (42); pesos (38).

Fuente específica: [17] · voces «convolution» y «convolutional operation».

---

16 · Descenso de gradiente

Gradient descent

Definición técnica: Procedimiento iterativo de optimización que modifica parámetros en la dirección opuesta al gradiente de una función de pérdida [17].

En palabras sencillas: Si una predicción produce mucho error, se realizan pequeños cambios para intentar reducirlo.

Aplicación: Hipotético: optimizar los parámetros de una red que estima la calidad de un producto.

Conexiones: Pesos (38); retropropagación (40); aprendizaje profundo (13).

Fuente específica: [17] · voces «gradient descent» y «gradient».

---

05 · Aprendizaje por refuerzo

Fichas numeradas, fuentes rastreables y conexiones con otras entradas.

17 · Agente de aprendizaje por refuerzo

Reinforcement learning agent

Definición técnica: Entidad que selecciona acciones al interactuar con un entorno y busca maximizar una recompensa acumulada esperada [10].

En palabras sencillas: El agente aprende probando decisiones y observando consecuencias; no equivale necesariamente a un agente generativo.

Aplicación: Hipotético: un robot de almacén aprende rutas eficientes con penalización por choques.

Conexiones: Entorno (18); política (19); agentes de IA (53).

Fuente específica: [10] · apartado «Why Gymnasium?» y API «Env».

---

18 · Entorno

Environment

Definición técnica: Sistema externo al agente que evoluciona después de cada acción y devuelve observaciones y señales de recompensa [10].

En palabras sencillas: Es el mundo con el que el agente practica y del que recibe retroalimentación.

Aplicación: Hipotético: simulador de tráfico que cambia semáforos y registra congestión.

Conexiones: Agente de aprendizaje por refuerzo (17); recompensa (20); política (19).

Fuente específica: [10] · apartado «Env.step()».

---

19 · Política

Policy

Definición técnica: Regla o distribución que determina qué acción elige un agente según el estado u observación disponible [20].

En palabras sencillas: Es la estrategia que decide qué hacer en cada situación.

Aplicación: Hipotético: una política decide si una batería se carga o descarga según su nivel y el precio eléctrico.

Conexiones: Agente de aprendizaje por refuerzo (17); entorno (18); recompensa (20).

Fuente específica: [20] · apartado «Training an Agent», política de selección de acciones en Q-learning.

---

20 · Recompensa

Reward

Definición técnica: Señal numérica emitida por el entorno tras una acción que sirve como criterio de aprendizaje para una política [10].

En palabras sencillas: Un premio o penalización indica si una decisión ayuda al objetivo a largo plazo.

Aplicación: Hipotético: +10 por una entrega puntual y -5 por cada retraso.

Conexiones: Política (19); entorno (18); agente de aprendizaje por refuerzo (17).

Fuente específica: [10] · API «Env.step()», campo «reward».

---

06 · Algoritmos y aplicaciones

Fichas numeradas, fuentes rastreables y conexiones con otras entradas.

21 · Regresión logística

Logistic regression

Definición técnica: Modelo lineal para clasificación que transforma una combinación de características mediante una función logística para estimar probabilidades de clase [6].

En palabras sencillas: Pese a su nombre, normalmente se usa para decidir entre categorías, como sí/no.

Aplicación: Hipotético: probabilidad de que un usuario cancele una suscripción.

Conexiones: Clasificación (07); odds (26); log-odds (27).

Fuente específica: [6] · sec. «1.1.11 Logistic regression».

---

22 · Árbol de decisión

Decision tree

Definición técnica: Modelo supervisado no paramétrico que aprende reglas de división sucesivas sobre variables para predecir clases o valores [7].

En palabras sencillas: Sigue preguntas de tipo «si ocurre X, pasa por esta rama» hasta obtener una predicción.

Aplicación: Hipotético: clasificar solicitudes de mantenimiento según horas de operación y temperatura.

Conexiones: Bosque aleatorio (23); clasificación (07); regresión (08).

Fuente específica: [7] · sec. «1.10 Decision Trees».

---

23 · Bosque aleatorio

Random forest

Definición técnica: Ensamble de árboles construidos con muestreo aleatorio de observaciones y selección de variables, cuyas predicciones se combinan [8].

En palabras sencillas: En vez de confiar en un solo árbol, reúne muchos para mejorar la estabilidad de la predicción.

Aplicación: Hipotético: estimar probabilidad de falla con sensores, antigüedad y registros de inspección.

Conexiones: Árbol de decisión (22); clasificación (07); aprendizaje supervisado (05).

Fuente específica: [8] · sec. «1.11.2.1 Random Forests».

---

24 · Máquina de vectores de soporte (SVM)

Support vector machine (SVM)

Definición técnica: Familia de métodos supervisados que construye funciones de decisión apoyadas en vectores de soporte; en clasificación busca una separación con margen adecuado [9].

En palabras sencillas: Intenta trazar una frontera útil entre grupos; con kernels puede crear fronteras no lineales.

Aplicación: Hipotético: diferenciar componentes conformes y defectuosos a partir de medidas calibradas.

Conexiones: Clasificación (07); escalado (36); árbol de decisión (22).

Fuente específica: [9] · sec. «1.4 Support Vector Machines».

---

07 · Odds y probabilidades

Fichas numeradas, fuentes rastreables y conexiones con otras entradas.

25 · Probabilidad

Probability

Definición técnica: Medida entre 0 y 1 de la plausibilidad de un evento dentro de un modelo probabilístico; P(A) indica la probabilidad del evento A [3].

En palabras sencillas: Una probabilidad de 0,20 equivale a 20 % de posibilidad según el modelo, no a 20 % de odds.

Aplicación: Hipotético: estimar P(falla)=0,20 para una máquina durante un periodo.

Conexiones: Odds (26); log-odds (27); odds ratio (28).

Fuente específica: [3] · voces «probability» y «log-odds».

---

26 · Odds (razón a favor)

Odds

Definición técnica: Para un evento con probabilidad p, las odds a favor son p/(1-p) cuando $0 \leq p < 1$; comparan ocurrencia con no ocurrencia [3].

En palabras sencillas: No son una probabilidad: con p=0,75 las odds equivalen a 3:1.

Aplicación: Ejemplo calculado: p=0,20 implica odds=0,20/0,80=0,25=1:4.

Conexiones: Probabilidad (25); log-odds (27); regresión logística (21).

Fuente específica: [3] · voz «log-odds», apartado que define «odds».

---

27 · Log-odds (logit)

Log-odds / logit

Definición técnica: Logaritmo natural de las odds: $\text{logit}(p)=\ln[p/(1-p)]$ para $0 < p < 1$ [3].

En palabras sencillas: Convierte una probabilidad limitada entre 0 y 1 en una escala que puede tomar valores positivos o negativos.

Aplicación: Ejemplo calculado: si p=0,50, log-odds=ln(1)=0; si p=0,75, ln(3)≈1,10.

Conexiones: Odds (26); probabilidad (25); regresión logística (21).

Fuente específica: [3] · voz «log-odds».

---

28 · Razón de momios (odds ratio)

Odds ratio (OR)

Definición técnica: Cociente entre las odds correspondientes a dos grupos o condiciones, OR=odds(A)/odds(B), utilizado para comparar asociación [21].

En palabras sencillas: Una OR de 2 significa odds dobles, no necesariamente probabilidad doble; no prueba causalidad.

Aplicación: Ejemplo calculado: odds A=2 y odds B=1, entonces OR=2.

Conexiones: Odds (26); probabilidad (25); regresión logística (21).

Fuente específica: [21] · apartado «Clinical Overview», fórmula de odds ratio.

---

08 · Texto computacional

Fichas numeradas, fuentes rastreables y conexiones con otras entradas.

29 · Procesamiento del lenguaje natural (PLN)

Natural language processing (NLP)

Definición técnica: Área de IA y lingüística computacional enfocada en analizar, representar o generar lenguaje humano mediante métodos computacionales [17].

En palabras sencillas: Permite trabajar con textos o conversaciones como datos.

Aplicación: Hipotético: clasificar comentarios de clientes por tema y urgencia.

Conexiones: Tokenización (30); TF-IDF (31); embedding (32).

Fuente específica: [17] · voz «natural language processing».

---

30 · Tokenización

Tokenization

Definición técnica: Proceso que segmenta texto en unidades denominadas tokens y permite convertirlas en identificadores procesables por un modelo [12].

En palabras sencillas: Una frase se descompone en piezas: palabras, fragmentos o símbolos, según el tokenizador.

Aplicación: Hipotético: convertir «falla del motor» en piezas codificadas antes de procesarla.

Conexiones: PLN (29); embedding (32); LLM (50).

Fuente específica: [12] · sección «Tokenizers».

---

31 · TF-IDF

Term frequency–inverse document frequency

Definición técnica: Esquema de ponderación numérica para texto que combina la frecuencia de un término en un documento con la rareza del término en el corpus [19].

En palabras sencillas: Da más peso a palabras útiles para diferenciar documentos y menos a palabras presentes casi en todos.

Aplicación: Hipotético: representar reportes técnicos para buscar los más parecidos a una descripción de falla.

Conexiones: Tokenización (30); embedding (32); PLN (29).

Fuente específica: [19] · sección «Text feature extraction», apartados «Tf–idf term weighting».

---

32 · Embedding

Embedding / vector representation

Definición técnica: Representación numérica densa de una entrada en un espacio vectorial aprendible o aprendido, diseñada para codificar características y relaciones relevantes [16].

En palabras sencillas: Textos de significado cercano pueden quedar cerca en un espacio matemático, aunque no siempre.

Aplicación: Hipotético: representar preguntas de clientes como vectores para recuperar manuales relacionados.

Conexiones: TF-IDF (31); RAG (52); base de datos vectorial (58).

Fuente específica: [16] · voz «embedding».

---

09 · Vecino más cercano

Fichas numeradas, fuentes rastreables y conexiones con otras entradas.

33 · K vecinos más cercanos (KNN)

K-nearest neighbors (KNN)

Definición técnica: Método basado en instancias que predice utilizando las K observaciones de entrenamiento más cercanas según una métrica de distancia [5].

En palabras sencillas: Para un caso nuevo consulta ejemplos parecidos y los utiliza para votar una clase o promediar valores.

Aplicación: Hipotético: clasificar una flor a partir de cinco flores previamente medidas.

Conexiones: Número de vecinos K (34); distancia euclidiana (35); escalado (36).

Fuente específica: [5] · secs. «1.6 Nearest Neighbors» y «1.6.2 Nearest Neighbors Classification».

---

34 · Número de vecinos K

Number of neighbors K

Definición técnica: Hiperparámetro que especifica cuántas observaciones cercanas contribuyen a una predicción KNN [5].

En palabras sencillas: Un K pequeño reacciona mucho a casos individuales; uno grande suaviza más, pero puede ignorar patrones locales.

Aplicación: Hipotético: comparar predicciones KNN con K=1, K=5 y K=15 usando validación.

Conexiones: KNN (33); distancia euclidiana (35); escalado (36).

Fuente específica: [5] · sec. «1.6.2 Nearest Neighbors Classification», selección de K.

---

35 · Distancia euclidiana

Euclidean distance

Definición técnica: Métrica entre dos vectores x e y: $d(x,y)=\sqrt{\Sigma_i(x_i-y_i)^2}$, correspondiente a la distancia en el espacio euclidiano [5].

En palabras sencillas: Mide cuán lejos están dos registros cuando se expresan con variables comparables.

Aplicación: Ejemplo calculado: entre (1,2) y (4,6), $d=\sqrt{(3^2+4^2)}=5$.

Conexiones: KNN (33); escalado (36); K-means (10).

Fuente específica: [5] · sec. «1.6 Nearest Neighbors», métricas; fórmula euclidiana estándar.

---

36 · Escalado de características

Feature scaling

Definición técnica: Transformación de variables numéricas para llevarlas a escalas comparables antes de aplicar métodos sensibles a distancias o gradientes [5].

En palabras sencillas: Evita que una variable medida en miles domine a otra medida en décimas solamente por sus unidades.

Aplicación: Hipotético: estandarizar edad e ingresos antes de aplicar KNN.

Conexiones: Distancia euclidiana (35); KNN (33); PCA (12).

Fuente específica: [5] · sec. «1.6 Nearest Neighbors», sensibilidad a distancias; véase también ejemplo de clasificación KNN.

---

10 · Principios de redes neuronales

Fichas numeradas, fuentes rastreables y conexiones con otras entradas.

37 · Neurona artificial

Artificial neuron

Definición técnica: Unidad computacional que combina entradas ponderadas, un sesgo y frecuentemente una función de activación para producir una salida [17].

En palabras sencillas: Es un bloque de cálculo; muchas unidades conectadas pueden aprender funciones complejas.

Aplicación: Hipotético: neurona que recibe temperatura, presión y vibración para generar una señal intermedia.

Conexiones: Pesos (38); sesgo neuronal (39); capas (41).

Fuente específica: [17] · voz «neuron».

---

38 · Pesos de una red

Weights

Definición técnica: Parámetros multiplicativos aprendibles que modulan la contribución de entradas o activaciones a una neurona o capa [11].

En palabras sencillas: Durante el entrenamiento cambian para mejorar la predicción.

Aplicación: Hipotético: un peso alto da mayor influencia a una señal de vibración en una función aprendida.

Conexiones: Neurona artificial (37); sesgo neuronal (39); retropropagación (40).

Fuente específica: [11] · apartado «nn.Linear» y «Model Parameters».

---

39 · Sesgo neuronal

Bias parameter

Definición técnica: Término aditivo entrenable de una transformación afín que desplaza su respuesta respecto de la combinación de entradas [11].

En palabras sencillas: Permite ajustar el punto de activación sin cambiar todos los pesos.

Aplicación: Hipotético: una neurona produce señal incluso cuando todas sus entradas son cero, gracias a su sesgo.

Conexiones: Neurona artificial (37); pesos (38); retropropagación (40).

Fuente específica: [11] · apartados «nn.Linear» y «Model Parameters».

---

40 · Retropropagación

Backpropagation

Definición técnica: Algoritmo que aplica la regla de la cadena para calcular cómo cambia la pérdida respecto a los parámetros de capas anteriores [17].

En palabras sencillas: Calcula la contribución de cada peso al error; el optimizador usa esos gradientes para actualizar parámetros.

Aplicación: Hipotético: calcular gradientes de una CNN después de clasificar incorrectamente un defecto.

Conexiones: Descenso de gradiente (16); pesos (38); capas (41).

Fuente específica: [17] · voz «backpropagation».

---

11 · Estructura de redes neuronales

Fichas numeradas, fuentes rastreables y conexiones con otras entradas.

41 · Capas neuronales

Input, hidden and output layers

Definición técnica: Organización de una red en transformaciones de entrada, capas intermedias u ocultas y capa de salida que obtiene la predicción [11].

En palabras sencillas: La entrada recibe datos, las capas ocultas transforman representaciones y la salida genera el resultado.

Aplicación: Hipotético: una red toma 12 sensores, procesa dos capas ocultas y estima una probabilidad de avería.

Conexiones: Neurona artificial (37); CNN (42); transformer (44).

Fuente específica: [11] · apartados «Define the Class» y «Model Layers».

---

42 · Red neuronal convolucional (CNN)

Convolutional neural network (CNN)

Definición técnica: Arquitectura neuronal que contiene capas convolucionales con filtros compartidos para procesar estructuras espaciales como imágenes [17].

En palabras sencillas: Suele ser adecuada cuando importa reconocer patrones locales que aparecen en posiciones diferentes.

Aplicación: Hipotético: inspeccionar fotografías de productos para detectar rayones.

Conexiones: Convolución (15); capas neuronales (41); aprendizaje profundo (13).

Fuente específica: [17] · voz «convolutional neural network».

---

43 · Red neuronal recurrente (RNN)

Recurrent neural network (RNN)

Definición técnica: Arquitectura para secuencias que reutiliza conexiones o estados entre pasos temporales para incorporar información previa [17].

En palabras sencillas: Procesa datos en orden y conserva una memoria interna limitada de lo anterior.

Aplicación: Hipotético: analizar la secuencia de lecturas de un sensor para detectar eventos.

Conexiones: Capas neuronales (41); transformer (44); PLN (29).

Fuente específica: [17] · voz «recurrent neural network».

---

44 · Transformer

Transformer architecture

Definición técnica: Arquitectura neuronal para secuencias basada principalmente en mecanismos de atención, que modelan dependencias entre posiciones y admiten procesamiento altamente paralelo [17].

En palabras sencillas: Puede ponderar qué partes de una entrada importan para interpretar o producir otra parte.

Aplicación: Hipotético: un traductor automático relaciona palabras distantes de una oración.

Conexiones: LLM (50); tokenización (30); capas neuronales (41).

Fuente específica: [17] · voz «Transformer».

---

12 · Implicaciones sociales

Fichas numeradas, fuentes rastreables y conexiones con otras entradas.

45 · Sesgo algorítmico

Algorithmic bias

Definición técnica: Patrones sistemáticos de resultados potencialmente injustos o desiguales asociados con datos, decisiones de diseño o contexto de uso de sistemas de IA [13], [14].

En palabras sencillas: Un modelo puede funcionar bien en promedio y perjudicar de forma persistente a ciertos grupos.

Aplicación: Hipotético: una herramienta presenta falsos negativos más frecuentes para un subgrupo de usuarios.

Conexiones: Explicabilidad (46); privacidad (47); supervisión humana (48).

Fuente específica: [13], [14] · [13], marco de terminología de IA confiable; [14], principio «Fairness and non-discrimination».

---

46 · Explicabilidad

Explainability

Definición técnica: Capacidad de ofrecer razones comprensibles y pertinentes que ayuden a interpretar por qué un sistema produjo un resultado, considerando audiencia y contexto [14].

En palabras sencillas: No basta con mostrar la respuesta: debemos poder comunicar los factores relevantes o el proceso.

Aplicación: Hipotético: explicar qué variables influyeron en la clasificación de un préstamo, sin confundir explicación con causalidad.

Conexiones: Sesgo algorítmico (45); supervisión humana (48); árbol de decisión (22).

Fuente específica: [14] · principio «Transparency and explainability».

---

47 · Privacidad de datos

Data privacy

Definición técnica: Principio y conjunto de medidas orientadas a proteger información personal durante recopilación, entrenamiento, despliegue y uso de IA [14].

En palabras sencillas: Un sistema útil debe evitar recopilar o exponer datos personales sin base legítima y medidas adecuadas.

Aplicación: Hipotético: anonimizar reportes antes de utilizarlos en un modelo de clasificación.

Conexiones: Sesgo algorítmico (45); supervisión humana (48); RAG (52).

Fuente específica: [14] · principio «Right to privacy and data protection», párrs. 32-34.

---

48 · Supervisión humana

Human oversight

Definición técnica: Mecanismos por los que personas u organizaciones pueden comprender, vigilar e intervenir adecuadamente en decisiones y efectos de sistemas de IA [14].

En palabras sencillas: La máquina puede apoyar decisiones, pero deben existir responsables y opciones de corrección.

Aplicación: Hipotético: un profesional valida alertas médicas antes de ejecutar acciones clínicas.

Conexiones: Explicabilidad (46); privacidad (47); gobernanza de IA (60).

Fuente específica: [14] · principio «Human oversight and determination», párrs. 35-36.

---

13 · Ampliación: IA contemporánea

Fichas numeradas, fuentes rastreables y conexiones con otras entradas.

49 · Inteligencia artificial generativa

Generative AI

Definición técnica: Familia de sistemas de IA que aprende regularidades de datos y produce nuevas instancias de contenido, como texto, imágenes, audio o código [16].

En palabras sencillas: En vez de solo asignar etiquetas, crea material según instrucciones o contexto.

Aplicación: Hipotético: generar borradores de fichas técnicas para revisión humana.

Conexiones: LLM (50); modelo fundacional (51); alucinación (57).

Fuente específica: [16] · voz «generative AI».

---

50 · Modelo de lenguaje grande (LLM)

Large language model (LLM)

Definición técnica: Modelo de lenguaje entrenado a gran escala para procesar y generar secuencias de lenguaje mediante patrones estadísticos aprendidos [16].

En palabras sencillas: Predice y genera tokens y puede realizar tareas de redacción, resumen o preguntas y respuestas.

Aplicación: Hipotético: responder consultas sobre instrucciones técnicas usando contexto autorizado.

Conexiones: Transformer (44); tokenización (30); RAG (52).

Fuente específica: [16] · voz «large language model (LLM)».

---

51 · Modelo fundacional

Foundation model

Definición técnica: Modelo entrenado con amplios volúmenes de datos que puede adaptarse o utilizarse en múltiples tareas posteriores [16].

En palabras sencillas: Sirve como base reutilizable para crear aplicaciones distintas, no como solución completa a cualquier problema.

Aplicación: Hipotético: adaptar un modelo general para clasificar defectos en una línea de producción.

Conexiones: IA generativa (49); LLM (50); ajuste fino (56).

Fuente específica: [16] · voz «foundation model».

---

52 · Generación aumentada por recuperación (RAG)

Retrieval-augmented generation (RAG)

Definición técnica: Arquitectura que recupera información pertinente desde fuentes externas y la incorpora al contexto de un modelo generativo para producir una respuesta fundamentada [16].

En palabras sencillas: Primero consulta documentos relevantes y después usa esos fragmentos al responder; no equivale a reentrenar el modelo.

Aplicación: Hipotético: preguntar por procedimientos internos y recibir una respuesta vinculada a manuales vigentes.

Conexiones: LLM (50); embedding (32); base de datos vectorial (58).

Fuente específica: [16] · voz «retrieval-augmented generation (RAG)», pasos Retrieve/Augment/Generate.

---

53 · Agente de IA

AI agent

Definición técnica: Aplicación que recibe objetivos, utiliza un modelo y herramientas, toma decisiones y ejecuta acciones mediante un proceso de orquestación [16].

En palabras sencillas: Además de generar texto, puede consultar servicios o realizar una secuencia de pasos permitidos.

Aplicación: Hipotético: revisar inventario, consultar un API y proponer una orden de reposición para aprobación.

Conexiones: Agente de aprendizaje por refuerzo (17); LLM (50); prompt (55).

Fuente específica: [16] · voz «AI agents».

---

54 · Inteligencia artificial multimodal

Multimodal AI

Definición técnica: Sistema capaz de procesar o combinar distintas modalidades de información, como texto, imágenes, audio o video, dentro de una misma tarea [23].

En palabras sencillas: Puede relacionar lo que se ve con lo que se escucha o se escribe.

Aplicación: Hipotético: analizar una imagen de un repuesto junto con la descripción escrita del daño.

Conexiones: Modelo fundacional (51); IA generativa (49); prompt (55).

Fuente específica: [23] · apartado «What is an example of multimodal AI?».

---

55 · Prompt (instrucción de entrada)

Prompt

Definición técnica: Entrada o solicitud que se entrega a un modelo generativo para orientar la respuesta; puede incluir instrucciones, contexto y ejemplos [16].

En palabras sencillas: Es el planteamiento del problema para el modelo; su calidad influye, pero no garantiza precisión.

Aplicación: Hipotético: «Resume este procedimiento en cinco pasos y cita las secciones utilizadas».

Conexiones: LLM (50); RAG (52); alucinación (57).

Fuente específica: [16] · voz «prompting».

---

56 · Ajuste fino

Fine-tuning

Definición técnica: Proceso de adaptación de un modelo preentrenado mediante entrenamiento adicional con datos y objetivos específicos; puede actualizar todos o parte de sus parámetros [16].

En palabras sencillas: Modifica el comportamiento aprendido del modelo, a diferencia de simplemente adjuntarle documentos en un prompt.

Aplicación: Hipotético: adaptar un modelo para reconocer categorías propias de un catálogo técnico.

Conexiones: Modelo fundacional (51); RAG (52); pesos (38).

Fuente específica: [16] · voz «tuning», apartados «Full fine-tuning» y «Supervised fine-tuning».

---

57 · Alucinación de IA

AI hallucination

Definición técnica: Salida generada por un modelo que presenta afirmaciones no sustentadas, incorrectas o inventadas como si fueran fiables [16].

En palabras sencillas: Un texto fluido no garantiza verdad: la información debe contrastarse con fuentes.

Aplicación: Hipotético: un chatbot inventa una referencia bibliográfica o una pieza que no existe.

Conexiones: IA generativa (49); RAG (52); supervisión humana (48).

Fuente específica: [16] · voz «grounding», explicación de factualidad y alucinaciones.

---

58 · Base de datos vectorial

Vector database

Definición técnica: Sistema de almacenamiento e indexación que facilita recuperar objetos según la similitud entre vectores de alta dimensión [22].

En palabras sencillas: Permite buscar documentos que se parecen por su representación numérica en vez de coincidencias exactas de palabras.

Aplicación: Hipotético: recuperar manuales de mantenimiento próximos semánticamente a una pregunta.

Conexiones: Embedding (32); RAG (52); TF-IDF (31).

Fuente específica: [22] · apartado «Vector indexing».

---

59 · Modelo de difusión

Diffusion model

Definición técnica: Modelo generativo que aprende a transformar progresivamente señales ruidosas en muestras estructuradas, a menudo mediante un proceso de eliminación de ruido [17].

En palabras sencillas: Parte de ruido y va construyendo una imagen coherente en varios pasos, bajo condiciones apropiadas.

Aplicación: Hipotético: producir variaciones de imágenes conceptuales para prototipos visuales.

Conexiones: IA generativa (49); modelo fundacional (51); multimodalidad (54).

Fuente específica: [17] · voz «diffusion model» del glosario general.

---

60 · Gobernanza de IA

AI governance

Definición técnica: Conjunto de políticas, responsabilidades, procesos y controles para dirigir, evaluar y supervisar sistemas de IA a lo largo de su ciclo de vida [14].

En palabras sencillas: Define quién responde por el sistema, qué riesgos se aceptan, cómo se audita y cuándo intervenir.

Aplicación: Hipotético: establecer aprobación humana, registro de errores y revisión periódica de un modelo empresarial.

Conexiones: Supervisión humana (48); privacidad (47); sesgo algorítmico (45).

Fuente específica: [14] · apartados «Responsibility and accountability» y «Governance and stewardship».

Bibliografía en formato IEEE

Las referencias [n] están citadas en las fichas. Los enlaces se incorporan para facilitar la localización de la fuente; algunas obras base requieren acceso por biblioteca o compra. Fecha de consulta web: 4 de noviembre de 2026.

[1] O. Theobald, Machine Learning for Absolute Beginners: A Plain English Introduction, 2.a ed., Scatterplot Press, 2017.
https://books.google.co.uk/books/about/Machine_Learning_for_Absolute_Beginners.html?id=PGNzswEACAAJ
Libro base: referencia bibliográfica y estructura temática consultadas; verificar el pasaje en la edición disponible.

[2] A. Burkov, The Hundred-Page Machine Learning Book, 2019.
https://leanpub.com/theMLbook
Libro base: índice de capítulos y extractos de consulta; cotejar el texto final con el ejemplar del equipo.

[3] Google for Developers, «Machine Learning Glossary: ML Fundamentals», s. f.
https://developers.google.com/machine-learning/glossary/fundamentals
Glosario técnico: localizadores por encabezado de término.

[4] scikit-learn Developers, «2.3 Clustering», User Guide, s. f.
https://scikit-learn.org/stable/modules/clustering.html
Guía técnica: secciones 2.3.2 y 2.3.7.

[5] scikit-learn Developers, «1.6 Nearest Neighbors», User Guide, s. f.
https://scikit-learn.org/stable/modules/neighbors.html
Guía técnica: secciones 1.6, 1.6.2 y 1.6.3.

[6] scikit-learn Developers, «1.1 Linear Models», User Guide, s. f.
https://scikit-learn.org/stable/modules/linear_model.html
Guía técnica: regresión lineal y sección 1.1.11.

[7] scikit-learn Developers, «1.10 Decision Trees», User Guide, s. f.
https://scikit-learn.org/stable/modules/tree.html
Guía técnica: árbol de decisión y limitaciones.

[8] scikit-learn Developers, «1.11 Ensembles», User Guide, s. f.
https://scikit-learn.org/stable/modules/ensemble.html
Guía técnica: sección 1.11.2.1 Random Forests.

[9] scikit-learn Developers, «1.4 Support Vector Machines», User Guide, s. f.
https://scikit-learn.org/stable/modules/svm.html
Guía técnica: sección 1.4.

[10] Farama Foundation, «Basic Usage» y «Training an Agent», Gymnasium Documentation, s. f.
https://gymnasium.farama.org/introduction/basic_usage/
Documentación técnica: API Env y relación entre acción, observación y recompensa.

[11] PyTorch, «Build the Neural Network», PyTorch Tutorials, 2026.
https://docs.pytorch.org/tutorials/beginner/basics/buildmodel_tutorial.html
Tutorial técnico: Model Layers y Model Parameters.

[12] Hugging Face, «Tokenizers», Hugging Face Course, s. f.
https://huggingface.co/docs/course/chapter2/4
Curso técnico: conversión de texto a tokens numéricos.

[13] D. Atherton, R. Schwartz, P. Fontana y P. Hall, The Language of Trustworthy AI: An In-Depth Glossary of Terms, NIST AI 100-3, 2023, doi: 10.6028/NIST.AI.100-3.
https://www.nist.gov/publications/language-trustworthy-ai-depth-glossary-terms
Fuente institucional: alcance y terminología de IA confiable; confirmar voz en el texto original.

[14] UNESCO, «Recommendation on the Ethics of Artificial Intelligence», 2021.
https://www.unesco.org/en/legal-affairs/recommendation-ethics-artificial-intelligence
Recomendación institucional: principios de privacidad, supervisión y transparencia.

[15] OECD.AI, «Updated OECD Definition of an AI System», actualización de la definición de 2023, s. f.
https://oecd.ai/en/dashboards/policy-initiatives/updated-oecd-definition-of-an-ai-system-4108
Marco institucional: definición revisada del sistema de IA.

[16] Google Cloud, «Generative AI Glossary», Google Cloud Documentation, s. f.
https://docs.cloud.google.com/docs/ai-ml/generative-ai/glossary
Glosario técnico: headings exactos de modelos, RAG, prompts, agentes y embeddings.

[17] Google for Developers, «Machine Learning Glossary», s. f.
https://developers.google.com/machine-learning/glossary
Glosario técnico: entradas alfabéticas, CNN, RNN, tokens, sesgo y entrenamiento.

[18] scikit-learn Developers, «2.5.1 Principal component analysis», User Guide, s. f.
https://scikit-learn.org/stable/modules/decomposition.html#pca
Guía técnica: sección principal component analysis (PCA).

[19] scikit-learn Developers, «1.4 Feature extraction», User Guide, s. f.
https://scikit-learn.org/stable/modules/feature_extraction.html
Guía técnica: text feature extraction, bag of words y TF-IDF.

[20] Farama Foundation, «Training an Agent», Gymnasium Documentation, s. f.
https://gymnasium.farama.org/v1.3.0/introduction/train_agent/
Tutorial técnico: ejemplo de Q-learning tabular.

[21] S. Tenny y M. R. Hoffman, «Odds Ratio», StatPearls, actualización del 14 abr. 2026, NCBI Bookshelf.
https://www.ncbi.nlm.nih.gov/books/NBK431098/
Artículo de referencia: Introduction y Clinical Overview; definición y cálculo de odds ratio.

[22] Weaviate, «Vector Indexing», Weaviate Documentation, s. f.
https://docs.weaviate.io/weaviate/concepts/vector-index
Documentación técnica: apartado «Vector indexing» y explicación de vector databases.

[23] Google Cloud, «Multimodal AI», s. f.
https://cloud.google.com/use-cases/multimodal-ai
Guía técnica: apartado «What is an example of multimodal AI?».

Anexo A · Matriz de trazabilidad

Para cada referencia se indica el localizador de consulta y las fichas vinculadas. La matriz reproduce la relación de las citas internas; no equivale a una declaración de lectura íntegra de los libros.

[1] O. Theobald, Machine Learning for Absolute Beginners: A Plain English Introduction, 2.a ed., Scatterplot Press, 2017.

Localizador / enfoque: Libro base: referencia bibliográfica y estructura temática consultadas; verificar el pasaje en la edición disponible.

Entradas: 02

[2] A. Burkov, The Hundred-Page Machine Learning Book, 2019.

Localizador / enfoque: Libro base: índice de capítulos y extractos de consulta; cotejar el texto final con el ejemplar del equipo.

Entradas: 02, 05, 07, 08

[3] Google for Developers, «Machine Learning Glossary: ML Fundamentals», s. f.

Localizador / enfoque: Glosario técnico: localizadores por encabezado de término.

Entradas: 02, 03, 04, 05, 06, 07, 25, 26, 27

[4] scikit-learn Developers, «2.3 Clustering», User Guide, s. f.

Localizador / enfoque: Guía técnica: secciones 2.3.2 y 2.3.7.

Entradas: 09, 10, 11

[5] scikit-learn Developers, «1.6 Nearest Neighbors», User Guide, s. f.

Localizador / enfoque: Guía técnica: secciones 1.6, 1.6.2 y 1.6.3.

Entradas: 33, 34, 35, 36

[6] scikit-learn Developers, «1.1 Linear Models», User Guide, s. f.

Localizador / enfoque: Guía técnica: regresión lineal y sección 1.1.11.

Entradas: 08, 21

[7] scikit-learn Developers, «1.10 Decision Trees», User Guide, s. f.

Localizador / enfoque: Guía técnica: árbol de decisión y limitaciones.

Entradas: 22

[8] scikit-learn Developers, «1.11 Ensembles», User Guide, s. f.

Localizador / enfoque: Guía técnica: sección 1.11.2.1 Random Forests.

Entradas: 23

[9] scikit-learn Developers, «1.4 Support Vector Machines», User Guide, s. f.

Localizador / enfoque: Guía técnica: sección 1.4.

Entradas: 24

[10] Farama Foundation, «Basic Usage» y «Training an Agent», Gymnasium Documentation, s. f.

Localizador / enfoque: Documentación técnica: API Env y relación entre acción, observación y recompensa.

Entradas: 17, 18, 20

[11] PyTorch, «Build the Neural Network», PyTorch Tutorials, 2026.

Localizador / enfoque: Tutorial técnico: Model Layers y Model Parameters.

Entradas: 38, 39, 41

[12] Hugging Face, «Tokenizers», Hugging Face Course, s. f.

Localizador / enfoque: Curso técnico: conversión de texto a tokens numéricos.

Entradas: 30

[13] D. Atherton, R. Schwartz, P. Fontana y P. Hall, The Language of Trustworthy AI: An In-Depth Glossary of Terms, NIST AI 100-3, 2023, doi: 10.6028/NIST.AI.100-3.

Localizador / enfoque: Fuente institucional: alcance y terminología de IA confiable; confirmar voz en el texto original.

Entradas: 45

[14] UNESCO, «Recommendation on the Ethics of Artificial Intelligence», 2021.

Localizador / enfoque: Recomendación institucional: principios de privacidad, supervisión y transparencia.

Entradas: 45, 46, 47, 48, 60

[15] OECD.AI, «Updated OECD Definition of an AI System», actualización de la definición de 2023, s. f.

Localizador / enfoque: Marco institucional: definición revisada del sistema de IA.

Entradas: 01

[16] Google Cloud, «Generative AI Glossary», Google Cloud Documentation, s. f.

Localizador / enfoque: Glosario técnico: headings exactos de modelos, RAG, prompts, agentes y embeddings.

Entradas: 32, 49, 50, 51, 52, 53, 55, 56, 57

[17] Google for Developers, «Machine Learning Glossary», s. f.

Localizador / enfoque: Glosario técnico: entradas alfabéticas, CNN, RNN, tokens, sesgo y entrenamiento.

Entradas: 13, 14, 15, 16, 29, 37, 40, 42, 43, 44, 59

[18] scikit-learn Developers, «2.5.1 Principal component analysis», User Guide, s. f.

Localizador / enfoque: Guía técnica: sección principal component analysis (PCA).

Entradas: 12

[19] scikit-learn Developers, «1.4 Feature extraction», User Guide, s. f.

Localizador / enfoque: Guía técnica: text feature extraction, bag of words y TF-IDF.

Entradas: 31

[20] Farama Foundation, «Training an Agent», Gymnasium Documentation, s. f.

Localizador / enfoque: Tutorial técnico: ejemplo de Q-learning tabular.

Entradas: 19

[21] S. Tenny y M. R. Hoffman, «Odds Ratio», StatPearls, actualización del 14 abr. 2026, NCBI Bookshelf.

Localizador / enfoque: Artículo de referencia: Introduction y Clinical Overview; definición y cálculo de odds ratio.

Entradas: 28

[22] Weaviate, «Vector Indexing», Weaviate Documentation, s. f.

Localizador / enfoque: Documentación técnica: apartado «Vector indexing» y explicación de vector databases.

Entradas: 58

[23] Google Cloud, «Multimodal AI», s. f.

Localizador / enfoque: Guía técnica: apartado «What is an example of multimodal AI?».

Entradas: 54

Anexo B · Verificación pendiente antes de la entrega

☐ Confirmar autores, edición y pasajes de los dos libros exigidos en copias legítimas; registrar capítulo o página exacta en la matriz.

☐ Comprobar manualmente enlaces, disponibilidad pública y correspondencia entre cada definición y su localizador; corregir si alguna voz cambia.

☐ Pedir a cada integrante que revise conceptos y ejemplos; anotar diferencias entre fuentes cuando existan.

☐ Completar portada, equipo, comprobantes de acceso y carpeta compartida; registrar la intervención de IA como apoyo de redacción y verificación.

☐ Preparar el juego educativo aparte: la guía exige además 24 retos, cuatro mecánicas, reglas y prueba con usuarios.